



## **ОБЩА ХАРАКТЕРИСТИКА НА КОМПЮТЪРНОТО ЗРЕНИЕ, ИЗКУСТВЕНИТЕ НЕВРОННИ МРЕЖИ, МАШИННОТО ОБУЧЕНИЕ И ДЪЛБОКОТО ОБУЧЕНИЕ**

Много от човешките възприятия могат да се прехвърлят в компютърна среда и да се анализират с методите на изкуствения интелект. Това са всички машинни възприятия – компютърно зрение, машинен слух, докосване, обоняние, действие, общуване. Главно средство за получаване на информация за околната среда от човека е чрез системата за визуално възприемане.

Компютърното зрение е подобласт на AI и машинното обучение и основна негова задача, по аналог на човека, е възприемане, обработка и извличане на визуална информация от околната среда за даден обект с цел намаляване на неопределеността на обекта – източник на информация. В системата за компютърно зрение се изгражда модел за околната среда, с помощта на автоматизирано извличане на полезната информация, под формата на данни, от изображения или поредица от изображения. Данните от изображенията могат да бъдат получени от цифрови изображения, видео потоци, изгледи от множество камери, многомерни данни от медицински скенер и др. Областите на приложение на компютърното зрение се допълват от компютърната графика и цифровата обработка на изображения. Създадените чрез компютърната графика модели на двумерни (Two-Dimensional - 2D) или тримерни (Three-dimensional - 3D) изображения се анализират и интерпретират с помощта на цифровата обработка на изображения. Подобласти на компютърното зрение са: разпознаване и откриване на обекти, реконструкция на сцена, анализ на двумерни сцени, анализ на тримерни визуални сцени, откриване на събития, тримерно моделиране на сцена, оценка на движение, оценка на тримерна поза, оценка на качество, визуално управление, индексирание, възстановяване на изображение и др. За разлика от човешкото зрение, което е ограничено от видимата светлина, „методите на компютърно зрение, могат да се приложат за всяка област на електромагнитния спектър, където се получава изображение за наблюдаваната

[www.eufunds.bg](http://www.eufunds.bg)

*Проект BG05M2OP001-2.016-0003 „Модернизация на Национален военен университет "Васил Левски"- гр. Велико Търново и Софийски университет "Св. Климент Охридски" - гр. София, в професионално направление 5.3 Компютърна и комуникационна техника“, финансиран от Оперативна програма „Наука и образование за интелигентен растеж“, съфинансирана от Европейския съюз чрез Европейските структурни и инвестиционни фондове.*



среда, започвайки от рентгеновото излъчване, ултравиолетовата, видимата, инфрачервените области и радарните изображения“.

Изкуствените невронни мрежи са разработени от учени и вдъхновени по модела на предполагаемата структура на биологичните невронни мрежи, за да изпълняват „интелигентни“ задачи, подобни на тези, изпълнявани от човешкия мозък. Човешкият мозък възприема информация от околната среда чрез биологични неврони (нервни клетки), които с аспектите на своята организация са в основата на естествения интелект. Информацията, получена от невронните мрежи, се обработва на базата на обучение и опит, вземане на конкретни решения и обобщения. Изкуствените невронни мрежи са съставени от група от взаимосвързани елементи или възли, наречени изкуствени неврони, които са абстрактен модел на естествените неврони. Най-разпространената топология, на изкуствената невронна мрежа, се състои от входен (нулев) слой, скрит слой (един или повече) и изходен слой. Входните невронни елементи (входни единици) в нулевия слой получават входни величини под формата на набор от входни данни (множество от числени стойности, напр. на извадка, интензитет на пиксели от изображение, амплитуда във времето при звук, преобразуване на текст в числени стойности и др.), които източници на информация са външни за невронната мрежа. Общоприетият подход е да се приложи линейна трансформация на входните данни и на случаен принцип да се зададат малки произволни стойности за тегла, тъй като входните единици нямат претеглени входове. Входният слой изпраща данните към последващия скрит слой, посредством връзки (edges). В скрития слой невроните приемат набор от вероятностни входни величини, обработват ги и изчисляват своя изходна стойност. На получената матрица от стойности се прилага функция за активиране. Така получената изходна стойност се разпространява към един или няколко неврона към следващи скрити слоеве, или към изходния слой. Изходният слой в невронната мрежа е последният слой, който реализира целеви резултат или прогноза на системата.

Изкуствените неврони могат да бъдат линейни и нелинейни елементи. Това зависи от използваната функция на активация на отделните невронни елементи. Функциите на активиране могат да се прилагат и на слой от неврони.

[www.eufunds.bg](http://www.eufunds.bg)

*Проект BG05M2OP001-2.016-0003 „Модернизация на Национален военен университет "Васил Левски"- гр. Велико Търново и Софийски университет "Св. Климент Охридски" - гр. София, в професионално направление 5.3 Компютърна и комуникационна техника“, финансиран от Оперативна програма „Наука и образование за интелигентен растеж“, съфинансирана от Европейския съюз чрез Европейските структурни и инвестиционни фондове.*



Въвеждането на нелинейност в изкуствената невронна мрежа, с помощта на нелинейни функции за активиране, я прави способна да се справя със сложността на данните. Функциите за активиране извършват трансформация на получените величини, запазвайки стойностите им в приемлив и управляем диапазон. Нелинейните изкуствени неврони се свързват и взаимодействат с другите неврони, когато активацията им достигне определена стойност, праг. Стойността на тегловата величина, увеличена със стойността на изходната величина, определя силата и чувствителността на връзката, или въздействието между отделните неврони. Тегловите величини имитират функцията на мозъка, при която се променя асоциацията на невроните, използвайки изходната стойност на отделните неврони. Това е и най-фундаменталният механизъм в мозъка, който се осъществява в хипокампусната област отговорна за процесите на обучение, пространствените представи и паметта. Екип от изследователи откриват, че хипокампусните ансамбли от неврони, осигуряват значително времево кодиране в последователности от непространствени събития. Запазват прогресията в рамките на събитията и предсказват последователния ред на преживяванията. Комбинирайки електрофизиологични техники за запис при гризачи със статистически анализ на машинно обучение, на огромни масиви от данни, екипът е успял да наблюдава процеса на кодиране на информация в невроните на гризачите и да изследва модела на пикова активност в ансамбъл от неврони.

Изкуствените невронни мрежи имат способността да възпроизвеждат и моделират линейни и нелинейни процеси. Те са изчислителни графични модели на машинно обучение, основно алгоритми и са мощен инструмент за моделиране на данни. Изкуствените невронни мрежи имат регулируеми параметри, които могат да бъдат коригирани за да отговарят на данните – реални или симулирани. С помощта на целева функция (Objective Function) – функция на разходите (Cost Function) или функция на загубите (Loss Function), се цели да се сведе до минимум грешката в обучаемия модел. Целевата функция може да бъде локална и глобална по параметри, както и изрично включена, или имплицитно. Изкуствените невронни мрежи могат да се разглеждат като диференцируеми мрежови модели, които могат да бъдат подобрени с помощта на различни оптимизационни алгоритми като градиентно спускане, стохастично градиентно

[www.eufunds.bg](http://www.eufunds.bg)

*Проект BG05M2OP001-2.016-0003 „Модернизация на Национален военен университет "Васил Левски"- гр. Велико Търново и Софийски университет "Св. Климент Охридски" - гр. София, в професионално направление 5.3 Компютърна и комуникационна техника“, финансиран от Оперативна програма „Наука и образование за интелигентен растеж“, съфинансирана от Европейския съюз чрез Европейските структурни и инвестиционни фондове.*



спускане, метод за адаптивна скорост на обучение, метод на конюгатния градиент, оптимизация без деривати, оптимизация от нулев ред и др. Те получават входни данни, научават се да разпознават модели в набора от данни и след това прогнозираят резултата от нов набор от подобни данни. Биват прости и сложни невронни архитектури – в зависимост от посоката на предаване на информацията.

В зависимост от броя и вида на слоевете се делят на еднослойни и многослойни невронни мрежи. Еднослойните невронни мрежи са изградени от един входен и един изходен слой (невроните от входния слой служат само за съгласуване и разпределение на входните сигнали). Многослойната невронна мрежа, която се състои от един входен, скрит и изходен слой се нарича плитка невронна мрежа (Shallow Neural Network). Дълбоките невронни мрежи (Deep Neural Networks – DNNs) се приема, че имат входен слой (един или повече), множество скрити и изходен слой (един или повече).

Основното приложение на изкуствените невронни архитектури е да разпознават различни модели и структури, намирайки приложение в много области: разпознаване на модели – разпознаване на изображения, разпознаване на лица, радиолокационни системи; класификация на сигнали, разпознаване и реконструкция на обекти; разпознаване на последователности – жестомимичен език, разпознаване на реч, текст; идентификация и контрол на системи – контрол на превозни средства в реално време, прогнозиране на траектория; дизайн на лекарства; дизайн на химически продукти; контрол и динамично моделиране на машини и системи в производствени процеси; електроника – моделиране на чипове и анализ на повреда при чипове; автомобилостроене; аерокосмическо инженерство и технологии; механика, роботика; телекомуникации; филтриране на социални мрежи, филтриране на спам по имейл, превод на естествен език – проверка на правопис, автоматично довършване на думи при използване на търсачка, автоматична корекция на думи, интелигентно търсене, машинен превод, чат-ботове взаимодействащи с клиенти в социални мрежи, виртуални асистенти, поддръжка на база знания, автоматизация на обслужване на клиенти, анализ на проучване на нагласите на клиенти, мониторинг на социални медии и



др.; бизнес приложения – анализ на хедж фондове, маркетингово сегментиране и откриване на измами и много други.

Машинното обучение, като технологична област в изкуствения интелект, включва анализиране на информация под формата на данни и извличане на обучителен модел, или правило от тези данни. Така описаният процес на машинно обучение действа в две посоки – веднъж алгоритмите за машинно обучение преобразуват (изучават) модела от обучителните данни, а след това, обучененият модел се прилага към действителните входни данни за извеждане на прогнозен резултат. От решаващо значение за предвиждане на изходните данни, въз основа на входните променливи, е получаването на качествени и безпристрастни данни за обучение, които да отразяват вярно техните характеристики. По този начин обучененият модел се адаптира правилно към нови данни, извлечени от същото разпределение като това, използвано за създаване на модела, т. нар. обобщение (generalization). Машинното обучение има три основни подхода, които се разделят на по-широки категории, в зависимост от вида на решаваните задачи: контролирано обучение, неконтролирано обучение и обучение с утвърждение. Съществуват и други категории, които могат да припокриват няколко подхода - като смесено обучение, отнасящо се към контролирано и неконтролирано обучение; самоконтролирано обучение, което се причислява към методите на неконтролираното обучение; дълбоко структурирано обучение и др. Учебният процес при контролираното обучение предоставя на модела набор от етикетирани входни данни и правилни (целеви) изходни данни за съпоставка и извеждане на прогнозен резултат, т.е. за всеки входен сигнал, изпратен към мрежата по време на обучението, съществува съответен целеви изходен сигнал. С контролираното обучение се прави прогноза за категория или числова стойност за всеки вход, и се решават задачи като класификация и регресия (Classification and Regression). Обработването и аотирането на големи набори от данни, използвани в дълбокото обучение, е труден и времеемък процес, в повечето случаи дори нереализуем. Освен използването на техники като псевдоетикетиране на данните, полу-контролираното обучение има за цел да се справи с този проблем като използва малко количество маркирани данни и голям набор от немаркирани данни.

[www.eufunds.bg](http://www.eufunds.bg)

Проект BG05M2OP001-2.016-0003 „Модернизация на Национален военен университет "Васил Левски"- гр. Велико Търново и Софийски университет "Св. Климент Охридски" - гр. София, в професионално направление 5.3 Компютърна и комуникационна техника“, финансиран от Оперативна програма „Наука и образование за интелигентен растеж“, съфинансирана от Европейския съюз чрез Европейските структурни и инвестиционни фондове.





Ученето с подсилване е отделен подход в машинното обучение, при който агент за обучение с подсилване при предприемане на действия (положителни или отрицателни) в своята среда бива награждаван за действията си, с помощта на система от алгоритми. Агентът се учи от своя опит и се опитва да постигне най-доброто поведение. Ученето с подсилване използва набори от входни данни, част от изходни резултати и оценка за тези изходни данни. Агентът се обучава сам по метода проба-грешка за да генерира възможно най-много награди, което изисква много изчислителни ресурси. Неконтролираното обучение използва само входни данни, т.е. набори от данни без етикети, за намиране на различни модели и структури в данните. Методът се използва за задачи като групиране (Clustering), намаляване на размерността (Dimensionality Reduction), асоциативен анализ (Association Analysis). Самоконтролираното обучение решава задачи, които са от полето на контролираното обучение (класификация и регресия), но учейки се от немаркирани данни, което е задача на неконтролираното обучение. То е подход на машинното обучение, при който моделът се самообучава като получава надзорни сигнали (изработва входни стимули) от самите данни, често използвайки основната структура на данните. Моделът се самообучава да научи една част от входните данни от друга част от тях, като идентифицира всяка скрита част от входните данни, от всяка не скрита част, без да разчита на етикети. За намиране на характеристики в данните, които да не изглеждат като случаен шум, процесът на обучение трябва да се ползва също от голям набор от данни.

Самоконтролираното обучение автоматично генерира етикети и е известно още като предсказващо или претекстово обучение (predictive or pretext learning). Съществуват два етапа за самоконтролирано обучение. Първият е предварително обучение на модела и извършва т. нар. „претекстова задача“ (pretext task), „спомогателна задача“ (auxiliary task) или „задача преди обучението“ (pre-training task), която има за цел да насочи модела към научаване на междинни представяния от данните. Тази процедура още се нарича неконтролирано предварително обучение (Unsupervised Pre-Training Procedure). Вторият етап решава т. нар. „задачи надолу по веригата“ (downstream task), или това е процесът на предаване на знания от модела на претекст към решаване на конкретната задача. При тази процедура, моделът се обучава от край до край, и се извършва

[www.eufunds.bg](http://www.eufunds.bg)

Проект BG05M2OP001-2.016-0003 „Модернизация на Национален военен университет "Васил Левски"- гр. Велико Търново и Софийски университет "Св. Климент Охридски" - гр. София, в професионално направление 5.3 Компютърна и комуникационна техника“, финансиран от Оперативна програма „Наука и образование за интелигентен растеж“, съфинансирана от Европейския съюз чрез Европейските структурни и инвестиционни фондове.



т. нар. фина настройка за конкретните контролирани задачи надолу по веригата, като се използват теглата на предварително обучената мрежа за инициализиране на набора от данни. Самоконтролираното обучение е комбинация от стратегия за предварително обучение на модела и задача за фина настройка на задачите надолу по веригата.

Самоконтролираното обучение се използва широко в приложения за обработка на естествен език и изпълнява задачи като предсказване на централна дума, предсказване на съседни думи, предсказване на съседното изречение, авторегресивно езиково моделиране, предсказване на следващо изречение, моделиране на маскиран език, прогноза за реда на изречение, пермутация на изречението и др. При видео обработка може да предскаже минали или бъдещи кадри, от текущите наблюдавани кадри, както и да провери поредността им. Използва се за аудио обработка, за обработка на изображения и задачи за реконструкция

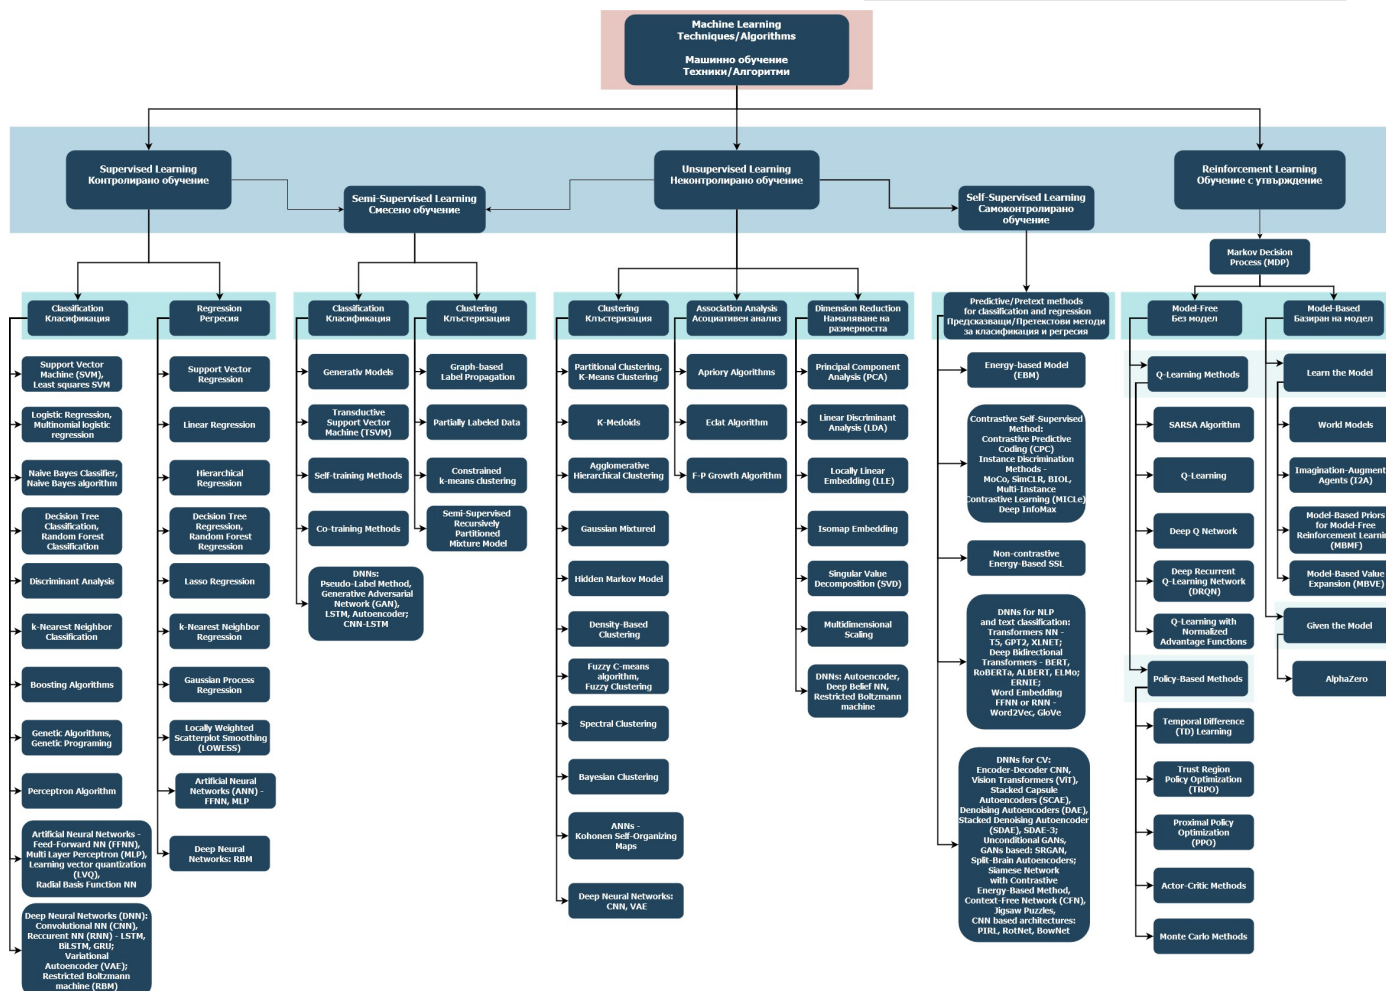
- оцветяване, мащабиране, придвиждане на цветовия канал, реконструиране на изображения, пъзели с изображения, генериране на изображения с висока разделителна способност, генериране на синтетични изображения, контекстно предсказване на изображения, разпознаване на геометрични трансформации, групиране на изображения и автоматично генериране на етикети (дълбоко групиране). Пионерите в областта на изкуствения интелект Ян Лекун, Джефри Хинтън и Йошуа Бенджио, изказват предположение на Тридесет и четвъртата конференция по изкуствен интелект, проведена в Ню Йорк, САЩ през 2020 г. (AAAI-20), че следващата революция в изкуствения интелект няма да бъде нито контролирана, нито подсилена, а бъдещето е на неконтролираното обучение и по-конкретно на самоконтролираното обучение.

На фигура 1 е предложена класификация на техниките за машинно обучение по категории, която се стреми да даде широк поглед върху най-популярните техники и алгоритми. Не се претендира за изчерпателност на посочените методи, тъй като приложното поле на машинното обучение е едно от най-бързо развиващите се.



Дълбокото структурирано обучение, по известно като дълбоко обучение, в днешно време се приема за основна част от приложното поле на изкуствения интелект и науката за данните. През последните две десетилетия, забележителните теоретични постижения в областта на компютърното зрение и изкуствените невронни мрежи доведоха до революционен подем в областта на дълбокото обучение. Компютърното зрение е област, в която дълбокото обучение се използва за изпълнение на широк спектър от задачи като обработка, анализ, класификация, синтез и реконструкция на изображения, откриване и сегментиране на обекти в изображения. В научните среди има спор „възможно ли е съществуването на дълбоко обучение без невронни мрежи?“. Много автори определят дълбокото обучение като клас алгоритми за машинно обучение за научаване на характеристики (Feature Learning), основани на изкуствени невронни мрежи. Други автори дефинират дълбокото обучение като подход, позволяващ на компютъра да научава сложни понятия от по-прости, подредени в йерархична графична структура, изградена от много слоеве – т.е. идеята за последователни слоеве от репрезентации. На конференцията AAAI-20, откривателят на метода на конволюционната мрежа Ян Лекун, казва в речта си: „Дълбокото обучение не е контролирано обучение. Това не са само невронни мрежи. Това е основно идеята за изграждане на система чрез сглобяване на параметризирани модули в изчислителен граф. Тези графи могат да бъдат динамични. Вие не програмирате директно системата. Вие дефинирате архитектурата и настройвате тези параметри. Могат да бъдат милиарди”.



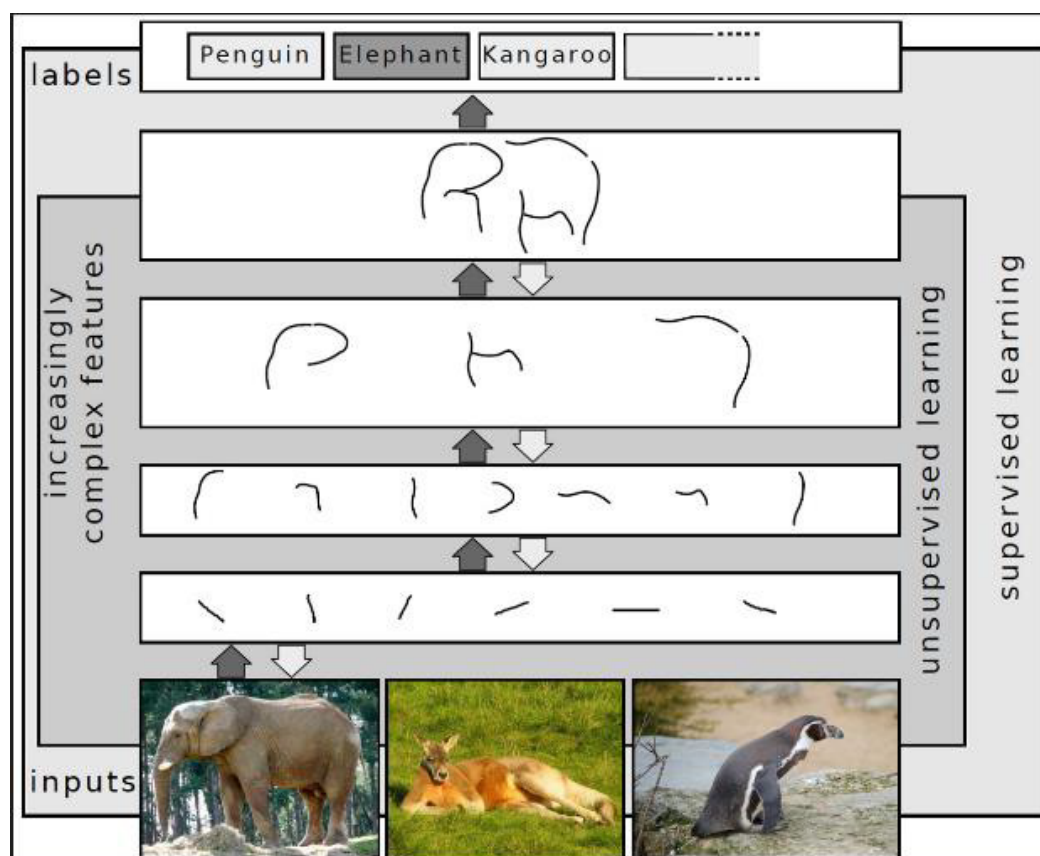


Фиг. 1. Таксономия на най-широко използваните методи за машинно обучение по категории.



Примерите на алгоритми за дълбоко обучение, са основани на изкуствени невронни мрежи. Дълбокото структурирано обучение се разглежда като широка рамка, в която моделът може да съществува и като йерархична графична структура, и като невронна мрежа.

Концепцията за дълбоко структурирано обучение, в която изчислителните модели са съставени от множество обработващи слоеве за постъпково извличане на характеристики от данните и подреждането им в последователна йерархична структура от слоеве, отговаря напълно и на двете определения. Тези слоеве са подредени във възходящ ред от ниско към по-високо ниво на абстракция на характеристики, както е показано на фигура 1, като по този начин се създава йерархия на характеристиките.



Фиг. 2. Извличане на характеристики от изображения и тяхното йерархично подреждане в множество слоеве на абстракция при дълбоко обучение.



Дълбокото обучение може да се отнесе и към науката за данни (Data Science), която използва различни методи (статистика и прогнозно моделиране) за извличане на знания и изводи от структурирани и неструктурирани данни. Дълбокото обучение може да се приложи към различни подходи на машинното обучение – контролирано обучение, неконтролирано, учене с подсилване и самоконтролирано обучение.

В контекста на изкуствените невронни мрежи, DL е основано на увеличаване на броя на слоевете, респективно дълбочината на изкуствената невронна мрежа, а също и наличието на скрити слоеве, през които данните се трансформират и представят с множество нива на абстракция. Дълбочината на мрежата се дефинира и като най-големият брой последователни, или напълно свързани слоеве, от входния до изходния слой.

При рекурентните невронни мрежи дълбочината може да се развива в две направления: по време (времева последователност) и по брой скрити слоеве.

Дълбоките невронни мрежи, използвани в компютърното зрение, имат изключително успешни приложения, надминаващи в някои случаи човешките възможности. Повечето от тях са свързани с контролираното обучение и големи обеми от данни, анотирани от човек. Ограниченията на машинното обучение и контролираното обучение се прехвърлят и върху дълбокото обучение. На първо място – изисква много голямо количество данни във фазата на обучение. Изследователската общност посочва за основен приоритет в дълбокото обучение намаляването на зависимостта от данните и създаването на системи с изкуствен интелект с ефективни данни. На следващо място - след като веднъж системата е намерила модела и е обучена, не винаги е ясно как взема решения. Използването на множество скрити слоеве в DNNs способства за откриване на сложни структури в големи набори от данни и е свързано с концепцията за „черна кутия“ (black box) в машинното обучение. Колкото повече стават слоевете и невронната мрежа става по-дълбока, толкова техниките за дълбоко обучение стават по-непрозрачни и неразбираеми дори за експертите в областта. Това е отделен клон на AI, който е известен като обясним изкуствен интелект (Explainable AI (XAI)) и има за цел да направи алгоритмите на машинното обучение по модел на „бялата



кутия“ (white box) – прозрачни и обясними, връщайки доверието между алгоритми и хора.

В компютърното зрение, специализираните дълбоки невронни мрежи за разпознаване на изображения имат множество подредени изкуствени неврони в серия от слоеве. Във входния слой, невронните елементи реагират на отделни пиксели от цифровото изображение, по начин аналогичен на човешкото зрение. Светлочувствителните невроепителни клетки подредени в няколко слоя в ретината на човешкото око, т. нар. рецепторно поле на окото, съставено от колбички и пръчици, реагират на светлинния и цветови интензитет, като възприемат и преобразуват електромагнитното излъчване от видимата част на спектъра в нервни импулси, които биват изпращани през зрителния нерв към мозъка.

Много от дълбоките изкуствени архитектури могат да се използват за изпълнение на задачи от приложното поле и на контролираното обучение, и на неконтролираното обучение. Така например конволюционната невронна мрежа, която е архитектура за решаване на задачи за контролирано обучение, често влизат в състава на дълбоки мрежи за неконтролирано обучение – дълбока конволюционна мрежа с убеждения (Convolutional Deep Belief Network – ConvDBN), дълбоки конволюционни генеративни състезателни мрежи (Deep Convolutional Generative Adversarial Network - DCGAN) и много други примери за хибридни архитектури. В зависимост от данните, които се подават на входа на невронната мрежа, тя може да реши задачи за класификация, регресия, клъстеризация (групиране), намаляване на размерността и др. Пример за това може да бъде автоенкодер невронна мрежа (Autoencoder - AE), която е вид изкуствена невронна мрежа за научаване на немаркирани данни чрез кодиране и предимно се използва за намаляване на размерността на данните. Успешно може да се справи с класификация на изображения, ако и се подаде на входа етикетирани набор от данни.

Прилагането на DL става възможно благодарение на въвеждането на сензорните мрежи, облачните структури и изчисления, големите данни (Big Data), суперкомпютрите и технологиите за своевременно събиране и съхраняване на големи обеми от информация в хранилища за данни. Според

[www.eufunds.bg](http://www.eufunds.bg)

*Проект BG05M2OP001-2.016-0003 „Модернизация на Национален военен университет "Васил Левски"- гр. Велико Търново и Софийски университет "Св. Климент Охридски" - гр. София, в професионално направление 5.3 Компютърна и комуникационна техника“, финансиран от Оперативна програма „Наука и образование за интелигентен растеж“, съфинансирана от Европейския съюз чрез Европейските структурни и инвестиционни фондове.*



доклад, публикуван от сайта Statista, през 2017 г. глобалните обеми от данни достигат 100 000 петабайта на месец, като се очаква в следващите години общото количество създадени, заснети, копирани и употребени данни да нарасне бързо, достигайки 180 зетабайта през 2025 г. Друг преломен момент в DL е започване използването на графични процесори (Graphics Processing Units – GPU) за обучение на невронни мрежи и многообразието от различни по големина широкомащабни бази данни като ImageNet (предназначена за визуално разпознаване на обекти с нейните 15 млн. ръчно анотирани изображения, разделени в 22 000 категории), MNIST с 60 хил. ръкописни цифри, CIFAR-10 с 60 хил. изображения, с ниска разделителна способност, разделени в 10 класа и т.н. От 2010 г. до 2017 г. академичните и изследователски общности се състезават с различни дълбоки архитектури за спечелване на годишния конкурс ImageNet Large Scale Visual Recognition Challenge (ILSVRC), оценявайки алгоритмите за откриване на обекти и класификация на изображения в голям мащаб. Една от водещите конференции за CV е именно представянето на методите и резултатите от предизвикателството, измервайки напредъка на CV за мащабно индексване на изображения за извличане и анотиране. Съществуват архитектурите на дълбоките невронни мрежи победители в ILSVRC, както и по-известните набори от данни за класифициране на изображения. Дълбоките невронни мрежи печелили ILSVRC през годините са:

- **AlexNet** 2012 г. (8 слойна Convolutional Neural Network - CNN),
- **ZF net** 2013 г. (9 слойна CNN),
- **VGG net** 2014 г. (16 слойна CNN),
- **GoogLeNet** 2015 г. (22 слойна CNN),
- **Microsoft ResNet** 2015 г. (152 слойна CNN),
- **ResNeXt** 2016 г. (50 и 101 слойни CNNs),
- **SeNet** 2017 г. (154 слойна).

Въведени са нови методи като класифициране, локализиране и откриване на обекти в изображения, задачи за CV в нарастващ ред на трудност, успешно решавани с дълбоки конволюционни мрежи. Надграждане на тези методи до сегментиране на екземпляри, постигнато чрез класифициране на всеки пиксел във фиксиран набор от категории.

[www.eufunds.bg](http://www.eufunds.bg)

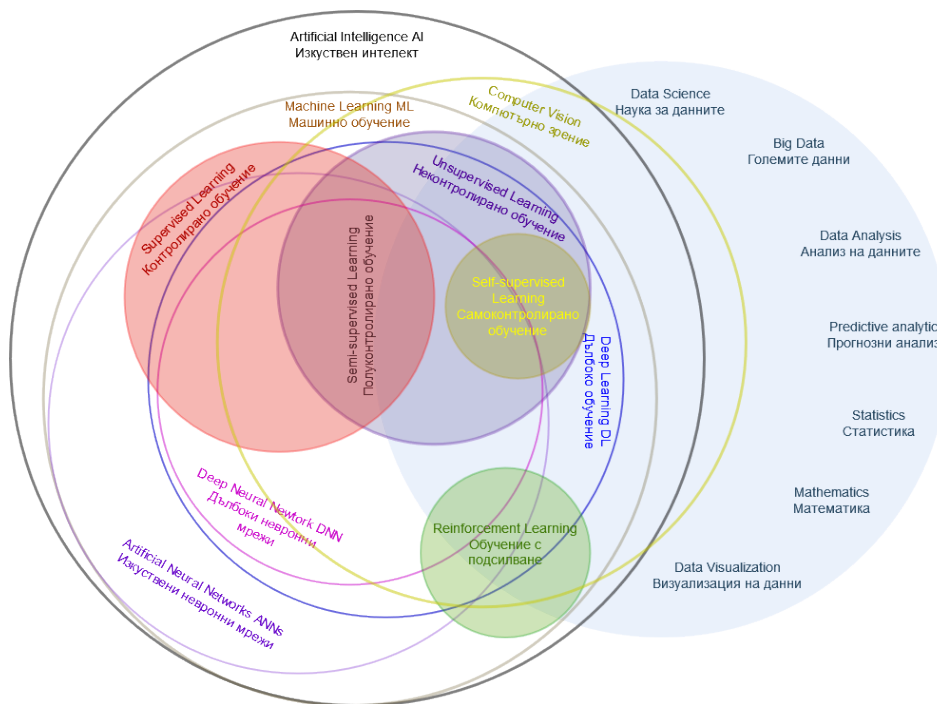
*Проект BG05M2OP001-2.016-0003 „Модернизация на Национален военен университет "Васил Левски"- гр. Велико Търново и Софийски университет "Св. Климент Охридски" - гр. София, в професионално направление 5.3 Компютърна и комуникационна техника“, финансиран от Оперативна програма „Наука и образование за интелигентен растеж“, съфинансирана от Европейския съюз чрез Европейските структурни и инвестиционни фондове.*





На фигура 3 е представена връзката между научното направление изкуствен интелект, основните видове машинно обучение, дълбокото обучение и компютърното зрение, както и интегрирани техники като изкуствените невронни мрежи. Отделните научни области – наука за данните, математика, статистика, както и някои техники, които са извън основната категория, функционират и самостоятелно. Посочени са като подпомагащи системите с компютърно зрение, в контекста на дълбокото обучение. В резултат на проведения анализ в този дисертационен труд се предлага следната Ойлерова диаграма.

Дълбокото структурирано обучение и дълбоките невронни мрежи намират широко приложение за решаване на много сложни задачи свързани с различни по вид изображения, извлечени от дистанционни наблюдения - биомедицинско инженерство, анализ на медицински изображения, разпознаване на жестове, автомобилно разпознаване, сателитни изображения, хиперспектрални изображения и др. За всички тях обединяваща характеристика е, че са получени от различни области от електромагнитния спектър.



Фиг. 3. Диаграма на Ойлер показваща връзката между AI, ML, CV, DL, ANNs, DNNs и други интегрирани научни области и технологии.

[www.eufunds.bg](http://www.eufunds.bg)

Проект BG05M2OP001-2.016-0003 „Модернизация на Национален военен университет "Васил Левски"- гр. Велико Търново и Софийски университет "Св. Климент Охридски" - гр. София, в професионално направление 5.3 Компютърна и комуникационна техника“, финансиран от Оперативна програма „Наука и образование за интелигентен растеж“, съфинансирана от Европейския съюз чрез Европейските структурни и инвестиционни фондове.