




ОБЩ ПРЕГЛЕД НА АЛГОРИТМИТЕ ЗА ДЪЛБОКО СТРУКТУРИРАНО ОБУЧЕНИЕ

Повечето алгоритми на DL са вдъхновени от човешкия мозък, наречен изкуствена невронна мрежа. Съвременният свят широко използва дълбокото обучение – от обработка на изображения до биомедицината и био-инженерството.

1. Невронни мрежи с право разпространение (FFNN).

Най-основният тип невронна мрежа, при която входната информация отива само в една посока, влизайки през изкуствени невронни възли и напускайки през изходни възли. В области, където скритите единици могат или не могат да присъстват, са налични входящи и изходящи слоеве. Разчитайки на това, човек може да ги класифицира като многослойна или еднослойна **невронна мрежа с право разпространение (Feed Forward Neural Network – FFNN)**. Тези мрежи имат проста архитектура и поради тази причина – широко разпространение в практиката.



Фиг. 1. Невронна мрежа с право разпространение (FFNN).



Основни функции

- Сложността на функцията определя броя на слоевете. Предаването на входната величина е еднопосочно и няма обратно разпространение.
- Освен това теглата са фиксирани. Входовете се комбинират с тегла и се подават към функция за активиране. За целта се използва функция за класификация или стъпално активиране.
- Ако добавянето на показанията е повече от предварително определен праг, който обикновено е зададен на нула, резултатът обикновено е 1. Ако сумата е по -малка от прага, изходната стойност обикновено е -1.
- Алгоритъмът за дълбоко обучение може да оцени резултатите от своите възли с желаните данни, като използва известна техника като делта правило, позволяващо на системата да променя своите тегла по време на обучението за създаване на по -прецизни изходни стойности.
- Алгоритъмът обаче няма плътни слоеве и разпространение назад, което не е подходящо при изчислително сложни задачи.

2. Многослоен перцептрон.

Това е точка за влизане в сложни невронни мрежи, където входните данни преминават през множество нива на изкуствени неврони. Всеки възел е свързан с всеки друг неврон в предстоящия слой, което води до напълно присъединена невронна мрежа. Входният и изходният слой са налични и между тях има скрит слой. Това означава, че всеки многослоен перцептрон има поне три слоя. Освен това той има мултимодално предаване, което означава, че може да се разпространява както напред, така и назад.


Основни функции

- Данните преминават през входния слой. След това алгоритъмът умножава входните данни със съответните им тегла в скрития слой и се добавя отклонението.
- След това умножените данни преминават към функцията за активиране. Според критериите за въвеждане се използват различни функции за



активиране. Например, повечето учени по данни използват сигмоидната функция.

- Освен това има функция за загуба за измерване на грешката. Най-често използваните са загуба на дневник, средна квадратна грешка, оценка на точността и т.н.
- В допълнение, алгоритъмът за дълбоко обучение използва техниката за обратно разпространение, за да намали загубата. След това теглата и отклоненията се променят чрез тази техника.
- Техниката продължава, докато загубата стане минимална. При минималната загуба се казва, че процесът на обучение е завършен.
- Многослойният перцептрон има много приложения, като сложна класификация, разпознаване на реч, машинен превод и др.



Фиг. 2. Невронна мрежа на базата на многослоен перцептрон.

3. Невронни мрежи с радиален базис (RBNN).

Невронните мрежи с радиален базис (Radial Basis Neural Network – RBNN) притежават слой с предавателна функция с радиален базис. Радиалната базисна функция анализира отстоянието на всяка точка спрямо центъра. Тези невронни мрежи имат две нива. Първо, атрибутите се сливат с радиалната базисна функция във вътрешния слой. След това, когато се изчислява същия резултат в следващия слой, се отчита изходът на тези атрибути. В допълнение към това, изходният слой има по един неврон за всяка категория. Алгоритъмът

www.eufunds.bg

Проект BG05M2OP001-2.016-0003 „Модернизация на Национален военен университет "Васил Левски"- гр. Велико Търново и Софийски университет "Св. Климент Охридски" - гр. София, в професионално направление 5.3 Компютърна и комуникационна техника“, финансиран от Оперативна програма „Наука и образование за интелигентен растеж“, съфинансирана от Европейския съюз чрез Европейските структурни и инвестиционни фондове.




използва сходството на входа за вземане на точки от тренировъчните данни, където всеки неврон поддържа прототип.

Основни функции

- Всеки неврон измерва евклидовото разстояние между прототипа и входа, когато трябва да се класифицира нов входен вектор, т.е. n -мерният вектор, който се опитвате да категоризирате.
- След сравнението на входния вектор с прототипа, алгоритъмът осигурява изход. Изходът обикновено варира от 0 до 1.
- Изходът на този RBF неврон ще бъде 1, когато входът съвпада с прототипа, и тъй като пространството между прототипа и входа се увеличава, резултатите ще се придвижат към нула.
- Кривата, създадена чрез активиране на неврон, прилича на стандартна крива на звънец. Група неврони съставлява изходния слой.
- В системите за възстановяване на мощността инженерите често използват невронна мрежа с радиална базисна функция. В опит да възстановят хранването за най-малко време, хората използват тази невронна мрежа в системите за възстановяване на хранването.

4. Рекурентни невронни мрежи (RNN).

Рекурентните невронни мрежи (Recurrent Neural Network – RNN) са вид невронна мрежа, в която резултатът от предишната фаза се предава в настоящата фаза като вход. За класическите невронни мрежи входът и изходът не са взаимозависими. Когато обаче трябва да предвидите някоя дума в изречението, трябва да вземете предвид предишната дума. Предсказването на следващата дума не е възможно без запомняне на последната дума. RNN се появи, за да решат този тип проблеми.



Фиг. 4. Рекурентна невронна мрежа (RNN).

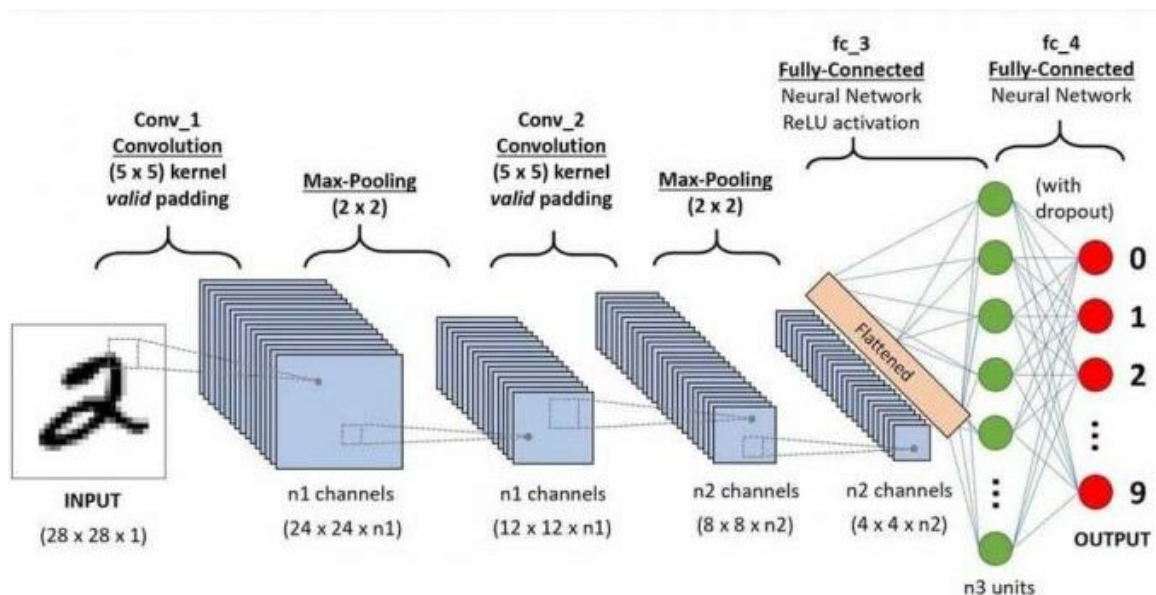
Основни функции

- Скритото състояние, което съхранява определени подробности за цикъл, е същественият елемент на RNN. Въпреки това основните характеристики на RNN зависят от това състояние.
- RNN притежават „памет“, която съхранява всички данни за изчисленията. Той използва същите настройки за всеки запис, тъй като произвежда един и същ резултат, като изпълнява една и съща команда на всички входове или скрити слоеве.
- RNN намалява усложнението, като преобразува автономните активирания в зависими, като дава на всички нива същите отклонения и тежести.
- В резултат на това той опростява процеса на обучение чрез надграждане на параметрите и запомняне на предишни резултати, като вкарва всеки резултат в следващото скрито ниво.
- Освен това всички тези слоеве могат да бъдат комбинирани в един повтарящ се слой, като отклоненията и теглото на всички скрити слоеве са еднакви.



5. Конволюционни невронни мрежи (CNN).

Конволюционната невронна мрежа (Convolutional Neural Network – CNN) е особено популярна при обработка на изображения, при което CNN невронната мрежа анализира всеки пиксел поотделно. След това теглата и отклоненията на модела се променят, за да се открие желаният обект от изображението. Подобно на други алгоритми, данните също трябва да преминат през етап на предварителна обработка. CNN обаче се нуждае от относително по-малко предварителна обработка от повечето други алгоритми DL.



Фиг. 5. Последователност от действия на конволюционна невронна мрежа.¹

Основни функции

- Във всеки алгоритъм за компютърно зрение изображението или сигналът трябва да преминат през процес на филтриране. CNN има много конволюционни слоеве, за да направи това филтриране.
- След конволюционния слой остава слой ReLU. Това означава поправена линейна единица. Той извършва операции с данните и извежда коригирана карта на атрибутите.

¹ <https://ciksiti.com/bg/chapters/5902-top-10-deep-learning-algorithms-that-every-ai-enthusiast-sho>



- Можем да намерим коригирана карта на характеристиките от слоя ReLU. След това преминава през обединяващия слой. Така че това е основно метод за вземане на проби.
- Обединяващият слой намалява размера на данните. Намаляването на размерите прави процеса на обучение сравнително по-евтин.
- Обединяващият слой изравнява двуизмерните матрици от агрегирания вектор на характеристиките, за да създаде единичен, дълъг, продължителен, последователен вектор.
- Напълно свързаният слой идва след обединяващия слой. Изцяло свързаният слой по същество има някои скрити слоеве на невронна мрежа. Този слой класифицира изображението в различни категории.

6. Мрежи с дългосрочна и краткосрочна памет (LSTM).

Рекурентните невронни мрежи основно работят с данни, свързани с глас. Те обаче не работят добре с така наречената „краткосрочна памет“ и имат трудности при транспортирането на информация от една стъпка към друга, ако веригата е достатъчно дълга. Ако се опитваме да прогнозираме нещо от пасаж на съдържание, RNN може да пропуснат критична информация. За да разрешат този проблем, изследователите са разработили модерна версия на RNN, наречена **мрежа с дългосрочна и краткосрочна памет (Long-Short-Term Memory – LSTM)**. Този алгоритъм за дълбоко обучение изключва проблема с „краткосрочната памет“.

Основни функции

- LSTM проследяват данните през цялото време. Тъй като могат да проследят минали данни, те са ценни при решаването на проблеми с времеви редове.
- Четири активни слоя се интегрират по специален начин в LSTM. В резултат на това невронните мрежи притежават структура като верига. Тази структура позволява на алгоритъма да извлича малка информация от съдържанието.

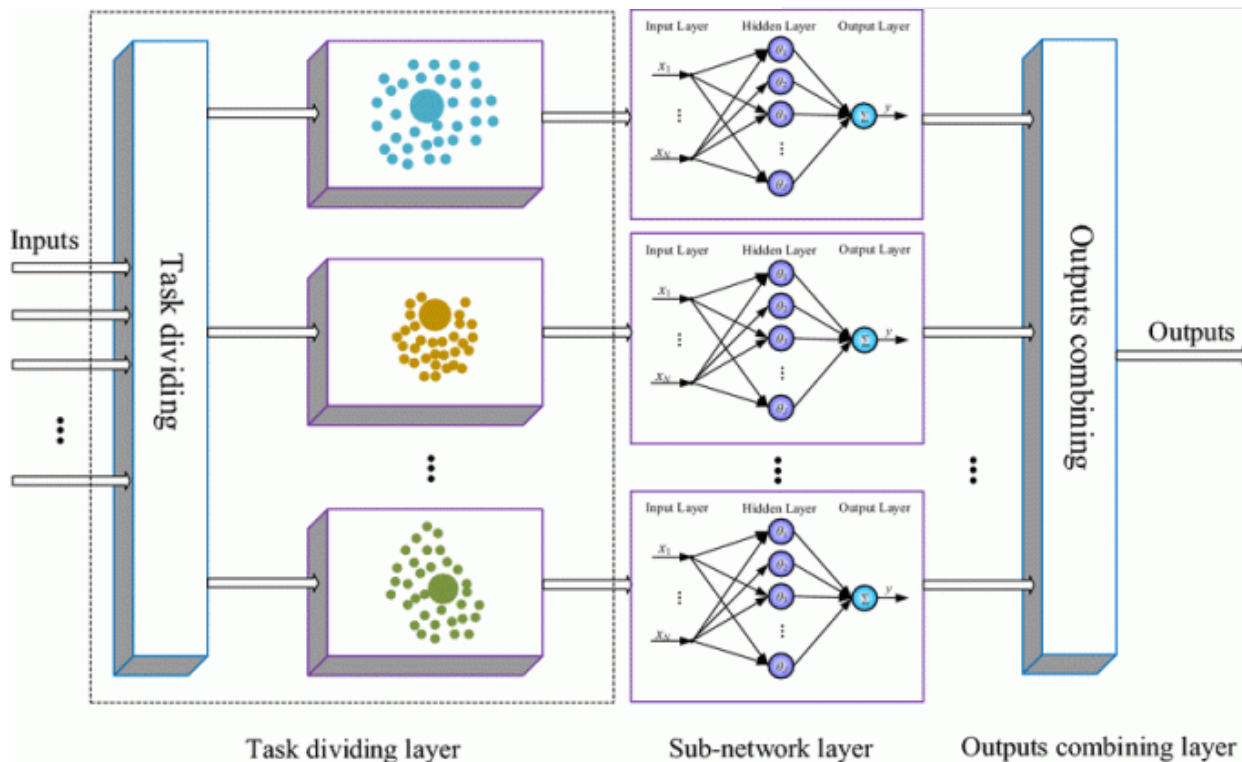


- Клетъчното състояние и многото му порти са в основата на LSTM. Състоянието на клетката служи като транспортен маршрут за съответните данни, докато се движи надолу по последователната верига.
- Теоретично състоянието на клетката може да запази необходимите подробности през цялото изпълнение на последователността. В резултат на това данните от предишни стъпки могат да намерят своя път към следващите времеви стъпки, намалявайки краткосрочните въздействия върху паметта.
- Освен прогнозиране на времеви редове, можете да използвате LSTM и в музикалната индустрия, разпознаване на реч, фармацевтични изследвания и др.

7. Модулни невронни мрежи (MNN).

Модулните невронни мрежи (Modular Neural Networks – MNN) комбинират няколко невронни мрежи, за да разрешат проблем. В този случай различните невронни мрежи действат като модули, като всяка решава част от проблема. Интегратор е отговорен за разделянето на проблема на множество модули, както и за интегрирането на отговорите на модулите, за да се формира крайния резултат на програмата.

Една обикновена невронна мрежа (Artificial Neural Network – ANN) не може да осигури адекватно представяне в много случаи в отговор на проблема и нуждите. В резултат на това може да изискваме множество ANN за справяне с едно и също предизвикателство. Модулните невронни мрежи са наистина страхотни в това.



Фиг. 7. Модулна невронна мрежа (MNN).

Основни функции


- Различни ANN се използват като модули в MNN за решаване на целия проблем. Всяка ANN символизира модул и отговаря за решаването на определен аспект на проблема.
- Този метод изисква съвместни усилия между многобройните ANN. Целта е да се раздели проблема на различни модули.
- Всеки ANN или модул е снабден с определен вход според неговата функция. Многобройните модули всеки се справя със собствения си елемент от проблема. Това са програмите, които изчисляват констатациите.
- Интегратор получава анализирания резултат. Работата на интегратора е да интегрира многобройните отделни отговори от многобройните ANN и да създаде комбиниран отговор, който служи като изход на системата.
- Следователно алгоритъмът за дълбоко обучение решава проблемите чрез метод от две части. За съжаление, въпреки многобройните



приложения, той не е подходящ при често променящи се начални условия и желани резултати, поради ниското ниво на адаптируемост.

8. Невронна мрежа от типа „от последователност към последователност“ (RNN-SSP).

Представлява комбинация от две рекурентни невронни мрежи, които формират **невронна мрежа от типа „от последователност към последователност“ (Recurrent Neural Networks Sequence-to-Sequence Patterns – RNN-SSP).**



Фиг. 8. Невронна мрежа от типа „от последователност към последователност“.



Тук има кодер за обработка на данните и декодер за обработка на резултата. Енкодерът и декодерът работят едновременно, използвайки едни и същи или отделни параметри.

За разлика от реалния RNN, този модел е особено полезен, когато количеството на входните данни и размерът на изходните данни са равни. Тези модели се използват предимно при системи за отговор на въпроси, машинни преводи и чат-ботове. Предимствата и недостатъците обаче са подобни на тези на RNN.

Основни функции

- Архитектурата на енкодер-декодер е най-основният метод за създаване на модела. Това е така, защото и енкодерът, и декодерът всъщност са LSTM модели.
- Входните данни отиват в енкодера и той трансформира целия въведен данни във вектори на вътрешно състояние.
- Този контекстов вектор се стреми да обхване данните за всички входни елементи, за да помогне на декодера да прави правилни прогнози.
- В допълнение, декодерът е LSTM, чиито начални стойности винаги са в крайните стойности на LSTM на енкодера, т.е. контекстният вектор на последната клетка на кодера влиза в първата клетка на декодера.
- Декодерът генерира изходния вектор, използвайки тези начални състояния, и отчита тези резултати за последващи отговори.

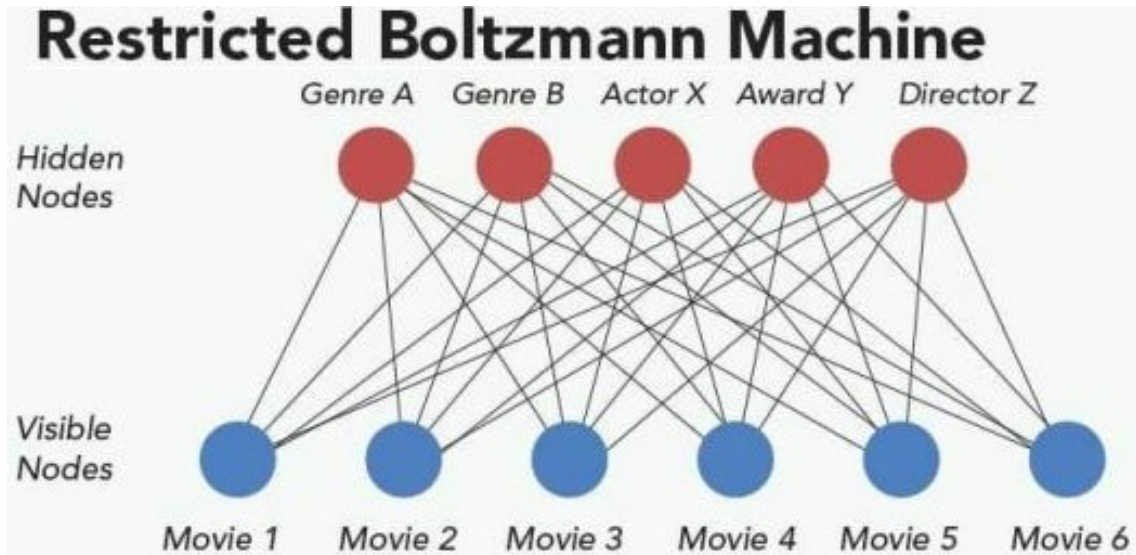
9. Ограничени машини на Болцман (RBM).

Джефри Хинтън разработва за първи път „болцманова машина с ограничения“ (Restricted Boltzman Machine – RBM). Това са стохастични невронни мрежи, които могат да се учат от вероятностно разпределение върху колекция от данни.

Този алгоритъм за дълбоко обучение има много приложения като изучаване на функции, съвместно филтриране на намаляване на измеренията, класификация, моделиране на теми и регресия.



RBM създават основната структура на мрежите за дълбоко вярване. Подобно на много други алгоритми, те имат два слоя: видимата единица и скритата единица. Всяка видима единица се свързва с всички скрити единици.



Фиг. 9. Невронна мрежа от типа „болцманова машина с ограничения“ (RBM).

Основни функции

- Алгоритъмът работи основно с комбинация от две фази – това са проходът напред и назад.
- При предаването напред, RBMs получават данните и ги преобразуват в набор от числа, които кодират входовете.
- RBM интегрират всеки вход със собствено претегляне и единно цялостно отклонение. Накрая изходът се предава на скрития слой по техниката.
- RBM придобиват тази колекция от цели числа и ги трансформират, за да генерират пресъздадените входове в обратния проход.
- Те смесват всяко активиране със собственото му тегло и общото отклонение, преди да предадат резултата на видимия слой за възстановяване.
- RBM анализира реконструирания данни до действителния вход на видимия слой, за да оцени ефективността на изхода.




10. Автоматични енкодери (Autoencoders, DAE).

Автоенкодерите (Autoencoders, Deep-Autoencoder – DAE) са подобни на невронните мрежи с право разпространение, където входът и изходът са със сходна архитектура.

През 80-те години на миналия век Джефри Хинтън създава автоенкодери за справяне с трудности при обучението. Те са невронни мрежи, които повтарят входовете от входния слой към изходния слой.

Автоенкодерите имат разнообразни приложения, включително обработка на изображения, откриване и прогнозиране на тенденции (trends).



Фиг. 10. Невронна мрежа от типа „автоматичен енкодер“.

Основни функции

- Автоенкодерът включва три слоя – енкодер, код и декодер.



- Дизайнът позволява да се вземе информация и да се преведе в различен контекст и след това да се пресъздаде реалния вход възможно най-точно.
- Понякога се използват като модел за филтриране или сегментиране.
- Автоенкодерите първо кодират картината, след което компресират данните в по-малка форма.
- Накрая се декодира изображението, което произвежда пресъздаденото изображение.
- Съществуват различни видове енкодери, всеки със собствено приложение.

През последните години алгоритмите за дълбоко структурирано обучение нараснаха в популярността си в широк кръг от бизнеси. Налични са различни невронни мрежи, които, макар и да работят по различни начини, дават отлични резултати. Всички тези качества са направили дълбокото обучение известно и широко използвано в практиката.