



## РАЗПОЗНАВАНЕ НА ИЗОБРАЖЕНИЯ С ИЗПОЛЗВАНЕ НА LSTM НЕВРОННА МРЕЖА

Задачата, свързана с разпознаване на обекти в изображения, може да се сведе до задача за сравнение между наблюдавано изображение и еталонно изображение (входове от тестов набор от данни). В съответствие с определени критерии се извършва класификация на обектите, която може да отнесе обекта към определен клас.

За обучението на изкуствените невронни мрежи и тестване на производителността на моделите се използват три типа набори от данни:

- набор от данни за обучение (training dataset) – използва се за коригиране на стойностите на тегловите матрици;
- набор от данни за валидиране (validation dataset) – използва се за минимизиране на проблем, известен като прекомерно напасване (настройване) към данните (overfitting) и помага за избора на обучителни алгоритми и параметри;
- набор от данни за тестване (testing dataset) – с тестовия набор се проверява колко точно е обучена изкуствената невронна мрежа.

Задачата за разпознаване на обекти в изображения може да се отнесе към следните задачи от полето на машинното обучение - класификация и класификация с липсващи входни величини.

При задачата за контролирано обучение като класификация, обученият алгоритъм посочва на изходният слой на невронната мрежа към коя от категориите  $k$  принадлежи дадена входна величина.

Алгоритъмът на обучение се представя с набор от входни величини, заедно с желаните от тях резултати (наричани още етикети – labels), като изпълнява следната функция:

$$f: \mathbb{R}^n \rightarrow \{1, \dots, k\},$$

където  $\mathbb{R}$  е множество на всички реалните числа за  $k = 1, 2, \dots, n$ ; с  $k$  се обозначава клас или категория, към която принадлежи дадена входна величина.



При  $y = f(x)$ , алгоритъмът за обучение присвоява входни величини, описани с вектор  $x$ , в категория  $y$ .

При решаване на задачата за класификация с липсващи входове, или т. нар. неконтролирано обучение, алгоритъмът се представя с набор от входове, но без да са посочени желани изходи, което означава, че алгоритъмът трябва да намира самостоятелно структури и модели от множество. Алгоритъмът за обучение трябва да дефинира еднофункционално съпоставяне на входен вектор към изходна категория и вместо да предоставя една функция за класификация следва да научи набор от функции, като всяка функция съответства на класифициране на  $x$  с липсващо подмножество, различно от нейните входове.

Наборът от данни (dataset) е колекция от много примери, с която се учи алгоритъма за обучение. Цифровите изображения са от съществено значение за машинното обучение и изкуствените невронни архитектури.

Освен големите набори от данни, необходими за обучението на DNNs, е важна и сложността на самото изображение, т.е. да се позволи на изкуствената невронна мрежа да се учи от големия брой функции, с които са дефинирани пробите, екземплярите (samples, instances)) в рамките на набора от данни.

Обучението „без учител“, включва наблюдение на няколко примера за произволен вектор  $x$  и опит за изрично научаване на вероятностното разпределение  $p(x)$ .

Обучение „с учител“ включва наблюдение на няколко примера за случаен вектор  $x$  и свързана стойност или вектор  $y$  и се научава да прогнозира  $y$  от  $x$ , обикновено чрез оценка на  $p(y|x)$ .

За решаване на поставената задача, е необходимо разработването на големи набори от данни, с които оптимално да се обучат моделираните сложни невронни архитектури.

Приема се, че обектите от еталонните модели на самолети и тези от възстановени радиолокационни изображения са инвариантни по отношение на мащаб и ориентация в кадъра. Създадените еталонни модели (цифрови изображения) са подложени на последваща цифрова обработка чрез внасяне на различни нива на добавен шум в изображенията, което симулира претрупана околна среда с електромагнитни смущения.

Предполага се, че нивото на шумове варира по случаен закон и в широки граници. Ако наблюдението на обекта продължава с последователно

[www.eufunds.bg](http://www.eufunds.bg)

Проект BG05M2OP001-2.016-0003 „Модернизация на Национален военен университет "Васил Левски"- гр. Велико Търново и Софийски университет "Св. Климент Охридски" - гр. София, в професионално направление 5.3 Компютърна и комуникационна техника“, финансиран от Оперативна програма „Наука и образование за интелигентен растеж“, съфинансирана от Европейския съюз чрез Европейските структурни и инвестиционни фондове.



генериране на множество радарни изображения, то изображенията на обекта се различават значително едно от друго, заради неговото движение. С наслагване на различни по вид и съотношение шум върху еталонните модели се генерират множество изображения на всеки от двадесет и двата летателни обекта. Всяко изображение симулира регистрирани различни на брой елементарни отражатели по повърхността на обекта, намиращи се в различно кинематично състояние, описвайки отделни части (точки) от неговата пространствена геометрия.

За генериране на наборите от данни е използван итеративен подход.

Използваните смущения са адитивен Гаусов шум с нормално разпределение (white Gaussian noise) и импулсен шум (Salt & pepper noise). Всеки еталонен модел на самолет (двоична матрица на изображение  $A$ ) се зашумява с внасяне на адитивен шум, като на всяка итерация се променят характеристиките на шума със стъпка на промяна 0.01.

Наборите от данни се описват като множество съдържащо  $m$  елементи:

$$\{I^{(1)}, I^{(2)}, \dots, I^{(m)}\},$$

където  $I$  е едно изображение от хомогенното множество, тъй като размерността на всички изображения е еднаква.

Създадени са три бази от данни с изображения с добавен гаусов шум и три с импулсен шум.

При генерирането на всеки набор с изображения се изменят характеристиките на съответния шум последователно както е посочено: от 0 до 0.51 със стъпка на промяна 0.01; от 0 до 0.71 със стъпка на промяна 0.01 и от 0 до 0.91 със стъпка на промяна 0.01.

Създадените набори от данни и техните характеристики са представени в Таблица 1, в зависимост от характеристиките на използваните два вида шум. С използването на различен брой екземпляри се цели постигането на приблизително еднаква големина на наборите от данни.



Таблица 1. Описание на създадените набори от изображения.

Име на набора от данни	Параметри на използвания шум	Нарастване на параметрите в диапазона	Брой екземпляри за всяка итерация	Брой изображения за всеки модел самолет	Общ брой изображения на набора от данни
1.database_with_Gaussian_noise_v0.52_m0.52_3	математическо очакване (mean [m]) и дисперсия (variance [v])	мат. очакване [m] и дисперсия [v] от 0 до 0.51	3	8 427	185 394
2.database_with_Gaussian_noise_v0.72_m0.72_2	математическо очакване (mean [m]) и дисперсия (variance [v])	мат. очакване [m] и дисперсия [v] от 0 до 0.71	3	10 368	228 096
3.database_with_Gaussian_noise_v0.92_m0.92_1	математическо очакване (mean [m]) и дисперсия (variance [v])	мат. очакване [m] и дисперсия [v] от 0 до 0.91	1	8 464	186 208
1.database_with_Salt&Pepper_noise_d0.52_160	плътност на разпределението (noise density [d])	плътност на разпределение [d] от 0 до 0.51	160	8 480	186 560
2.database_with_Salt&Pepper_noise_d0.72_120	плътност на разпределението (noise density [d])	плътност на разпределение [d] от 0 до 0.71	120	8 760	192 720
3.database_with_Salt&Pepper_noise_d0.92_90	плътност на разпределението (noise density [d])	плътност на разпределение [d] от 0 до 0.91	90	8 370	<b>184 140</b>


Броят изображения за всеки модел е постигнат от комбинирането на параметрите на съответния шум. Всеки екземпляр е създаден след като към определения еталонен модел е разпределен шум на случаен принцип, но с еднакви стойности на параметрите.

Присвояването на всеки пиксел на произволна вероятностна стойност от разпределението на шума в един модел не съвпада с разпределението на шума



в останалите модели. Приблизителното изравняване в разпределението на данните за обучение в различните бази от данни, както и в броя на изображенията по класове е за да бъде избегнато пристрастие към определени свръх представени класове.

На фигура 1 са посочени примерни изображения за модел An-158 от създадените бази с изображения с адитивен гаусов шум (фиг. 1а) и импулсен шум (фиг. 2б) с различна степен на постъпково зашумяване.



Фиг. 1. Създадени изображения на самолет An-158 в присъствие на различни нива адитивен гаусов шум (а) и импулсен шум (б)

Като част от експерименталните резултати ще бъдат изследвани разликите в производителността на обучените конволюционни невронни мрежи с еднаква архитектура и различни обучителни алгоритми.

Използваните обучителни алгоритми 'sgdm', 'adam' и 'rmsprop' са вградени за приложението Deep Network Designer.

Друг хиперпараметър, който ще бъде изследван е скоростта на обучение. Разширените обучителни параметри на скоростта на обучение като намаляване на скоростта на обучение по време на обучението (Learning Rate Schedule), брой епохи за отпадане на скоростта на обучение (Learning Rate Dropout Period), коефициент за намаляване на скоростта (Learning Rate Dropout Factor),





коэффициент за регулиране на L2, са зададени със стойности по подразбиране и няма да бъдат предмет на експеримент.

Инерционната константа е със стойност 0.9 и се прилага за всички реализирани модели невронни мрежи в настоящия труд.

Максималният брой епохи за обучение са зададени на 30 с използване на мини-партиди от по 128 резултата за наблюдение на всяка итерация.

Средата за изпълнение е избрана да бъде с използване на графичен процесор.

Мрежовите архитектури варират в зависимост от броя на включените слоеве и използваните параметри. Изборът на архитектури е аналогичен при изграждане на невронни архитектури и за двата вида добавен шум. Слоевите, които са използвани за обучение на реализираните модели архитектури са стандартни за мрежите с продължителна краткосрочна памет.

Първоначално е избрана LSTM архитектура с 11 слоя, тъй като класовете за обучение са малко на брой и изображенията не са хроматични.

Използваните слоеве на моделираните LSTM мрежи са следните (фиг. 2):

- *слой за въвеждане на последователност* (Sequence Input Layer) – входен слой, оразмерен за въвеждане на последователност от 2-D изображения, представени като вектор от три елемента  $[h \ w \ c]$ . Входният слой прилага и нормализиране на данните, винаги когато данните се разпространяват напред през него;
- *„изравняващ“ слой* (Flatten Layer) – изравняващият слой свива пространствените размери на входа до измерението на канала;
- *LSTM слой* (LSTM Layer) – научава дългосрочни зависимости между времевите стъпки от данните за последователността;
- *„отпадащ“ слой* (Dropout Layer) – по време на обучение, слойът за отпадане на случаен принцип настройва входните данни на нула за конкретна маска за отпадане. Тази операция ефективно променя основната мрежова архитектура между итерациите и помага да се предотврати прекомерното напасване на данните (overfitting). По-голямото число пропуска повече елементи по време на обучението;
- *напълно свързан слой* (Fully Connected Layer) – използва се за решаване на класификационна задача като комбинира характеристиките за класифициране

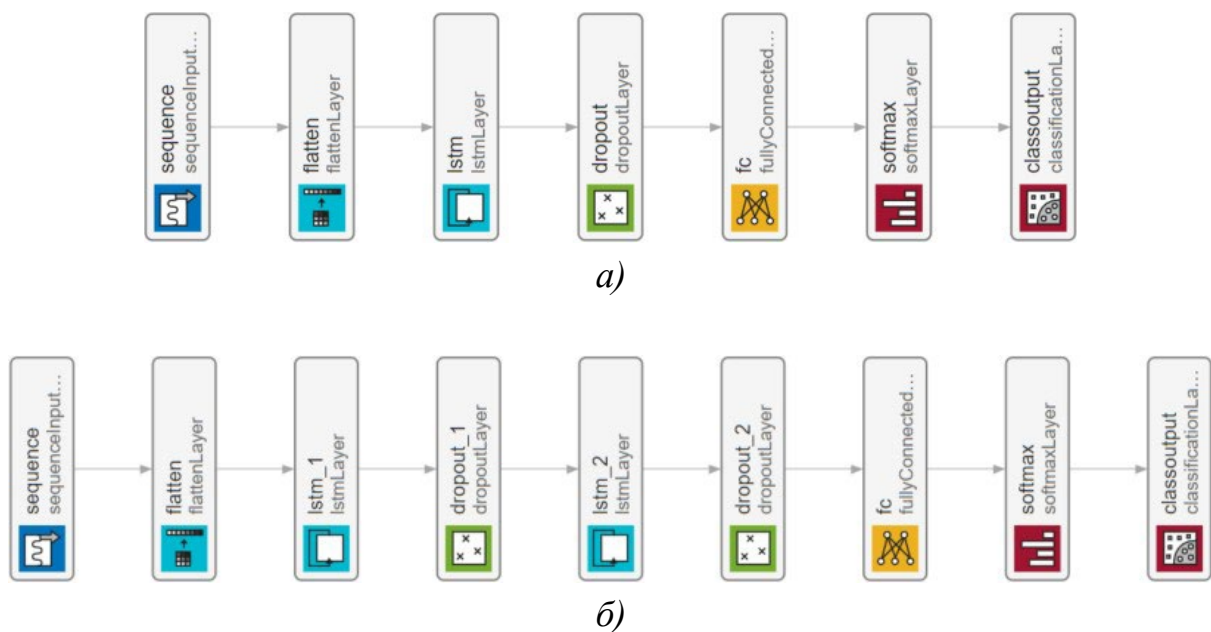


на изображенията. Параметърът изходен размер (Output size) е равен на броя на класовете в целевите данни;

- *SoftMax слой* (SoftMax Layer) - използва функция за активиране SoftMax, която нормализира изхода получен от напълно свързания слой. Резултатът от SoftMax слоя се състои от положителни числа, които се сумират до единица, в последствие могат да бъдат използвани като класификационни вероятности от класификационния слой [145];

- *класификационен слой* (Classification Layer) – изчислява загубата на кръстосана ентропия за класификационни задачи.

На фиг. 2. са изобразени използваните слоеве за обучение на 7-слойна и 9-слойна LSTM мрежа. За построяване на по-малки или по-големи мрежови архитектури се използват различни комбинации от посочените слоеве.



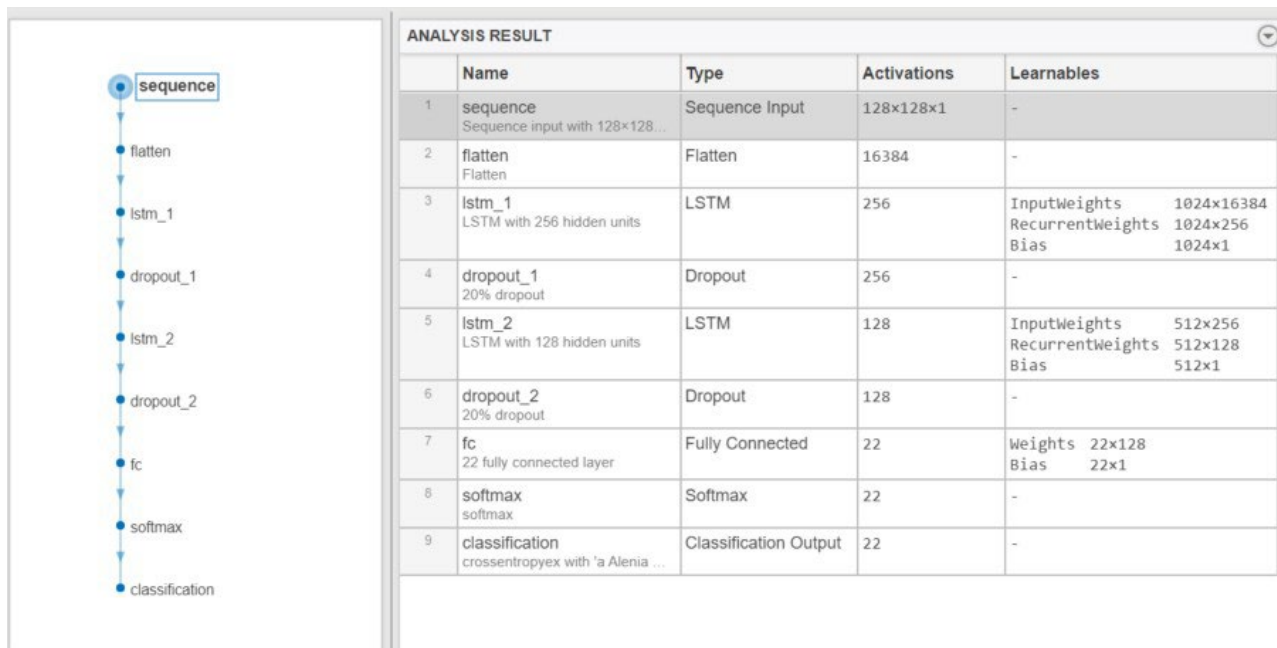
Фиг. 2. Модел на мрежова архитектура на обучените LSTM мрежи:  
7-слойни (а) и 9-слойни (б).

В двата LSTM слоя на обучените невронни мрежи са използвани различен брой скрити единици, като комбинациите са 256 за първия LSTM слой и 128 за втория, и съответно 200 на 128.

На фиг. 3 е показана подробна мрежова архитектура на 9-слойна LSTM мрежа обучена за разпознаване на изображения с добавен гаусов шум.

[www.eufunds.bg](http://www.eufunds.bg)

Проект BG05M2OP001-2.016-0003 „Модернизация на Национален военен университет "Васил Левски"- гр. Велико Търново и Софийски университет "Св. Климент Охридски" - гр. София, в професионално направление 5.3 Компютърна и комуникационна техника“, финансиран от Оперативна програма „Наука и образование за интелигентен растеж“, съфинансирана от Европейския съюз чрез Европейските структурни и инвестиционни фондове.



Фиг. 3. Модел на LSTM мрежова архитектура с 9 слоя.

Както може да се види от фигура 3, в изравняващия слой всяко изображение се преобразува във векторна последователност със съответните стойности за интензитет на пикселите.

Всеки от векторите се състои от **16384 елемента (неврона)**, колкото е броя на пикселите в изображението.

В следващия LSTM слой задаваме брой на скритите единици в LSTM клетката. Броят на скритите единици съответства на количеството информация, запомнена между времевите стъпки (скритото състояние).

Скритото състояние може да съдържа информация от всички предишни времеви стъпки, независимо от дължината на последователността.

Dropout е техника, която се използва за предотвратяване на overfitting при дълбоките невронни мрежи. Слоевете за отпадане се използват в различни видове невронни мрежи. Техниката работи като се задава стойност (0 до 1), с която на случаен принцип премахва съответния брой връзки между скритите единици, преобразувани в проценти между 0-100% при всяка актуализация на фазата на обучение.

При обучение на LSTM мрежите се използват dropout слоеве с два вида





стойности – 0.2 и 0.5, като в първия случай премахва 20 % от връзките между скритите единици, а във втория случай 50 %.

Напълно свързания слой (Fully Connected Layer) умножава входа по тегловната матрица  $W$  и след това добавя векторът на отклонението  $b$ .

Output size аргумента се задава на 22, колкото е броят на класовете в наборите от данни. След напълно свързания слой се поставя SoftMax слой, със SoftMax активационна функция, която получава данните от последния напълно свързан слой и активира изходния слой (classification layer).

Тя преобразува стойностите за всеки клас в интервала  $[0, 1]$ , като общата сума от всички класове е равна на единица, което е крайния числов резултат при разпознаването на мрежите).

В последния класификационен слой функцията Train Network взема стойностите от функцията SoftMax и присвоява всеки вход от нея на един от  $K$  взаимно изключващите се класове, използвайки функцията Cross Entropy (за кръстосана ентропия) със схема за кодиране 1 от  $K$ .

От фиг. 4 може още да се наблюдава изменението на активациите по слоеве, както и броя параметри във всеки от слоевете. В първия и втория LSTM слой обучаващите тегла се получават както следва – брой скрити неврони, умножени по четирите състояния на LSTM клетката, умножени по броя на елементите във вектор-стълба, образуван от изображението.

За обучение на LSTM невронните архитектури са използвани различни настройки на LSTM слоевете.

Използвани са 256, 200 или 128 броя на скритите единици, в различни комбинации между слоевете.

При наличие на един LSTM слой в мрежовата архитектура, изходният режим (output mode) е посочен с аргумент (Last). При наличие на два LSTM слоя, първият е зададен с аргумент последователност (Sequence), вторият с аргумент (Last).

Използвани са и двете функции за състояние на клетката (State activation function) – Tanh и Softsign.

За активираща функция на портите е приложена само сигмоидна функция (Gate activation function - Sigmoid).

Инициализацията на отклонението (Bias Initializer) е зададено по



подразбиране на елемент-забрави-порта (unit-forget-gate).


Част от настройките за процеса на обучение, които са използвани при LSTM мрежите за разпознаване на изображения, са зададени както следва:

- обучителен алгоритъм – SGDM;
- скорост на обучение – 0.001;
- инерционна константа – 0.9;
- среда за изпълнение – GPU;
- максимални епохи – 30;
- размер на мини-партидите – 128;
- честота на валидиране – 50 итерации;

Функцията за активиране *Softsign* има форма на графиката, много подобна на сигмоидната функция, но за разлика от нея е нулево центрирана на координатната ос. Изходният диапазон на функцията е еднакъв с този на хиперболична тангента,  $\{net \in \mathbb{R} \mid net \in (-1,1)\}$ . Функцията се дефинира съгласно следния израз:

$$f(net) = \frac{x}{|x|+1}$$

Графиката ѝ е показана на фиг. 4:



Фиг. 4. Графика на активационна функция *Softsign*.



В етапа на реализирането на моделите на LSTM невронни архитектури за разпознаване на изображения с адитивен гаусов шум е избрано обучението на моделите да започне с най-ниско добавено ниво на зашумяване в набора от данни - database\_with\_Gaussian\_noise\_v0.52\_m0.52\_3.

Обучени са 9-слойни архитектури и една 11-слойна.

Обучението на LSTM мрежите за разпознаване на изображения с добавен гаусов шум, с подадени различни мрежови параметри и различен вид набори от данни, както и архитектури са представени на Таблица 2.

Таблица 2. LSTM мрежови модели обучени за разпознаване на изображения с адитивен гаусов шум.

Брой слоевете	Нормализиране на данните	Активационна Функция на състоянието на слоеве LSTM	Набор от данни за обучение	Отпадащ слой (dropout техника с вероятност)	Брой скрити единици в LSTM слоевете	Достигната точност на валидиране [%]	Време за обучение [min, s]
9	zerocenter	1 слой – Tanh 2 слой – Tanh	database_with_Gaussian_noise_v0.52_m0.52_3	1 слой – 0.2 2 слой – 0.2	1 слой – 200 2 слой – 128	99.98 %	664 min 7 s
9	zscore	1 слой – Softsign 2 слой – Softsign	database_with_Gaussian_noise_v0.72_m0.72_2	1 слой – 0.2 2 слой – 0.5	1 слой – 256 2 слой – 128	100 %	278 min 45 s
9	zscore	1 слой – Softsign 2 слой – Softsign	database_with_Gaussian_noise_v0.92_m0.92_1	1 слой – 0.2 2 слой – 0.2	1 слой – 256 2 слой – 128	99.90 %	668 min 31 s
9	zerocenter	1 слой – Tanh 2 слой – Tanh	database_with_Gaussian_noise_v0.92_m0.92_1	1 слой – 0.2 2 слой – 0.2	1 слой – 256 2 слой – 128	99.84 %	668 min 31 s
9	zerocenter	1 слой – Softsign 2 слой – Softsign	database_with_Gaussian_noise_v0.92_m0.92_1	1 слой – 0.5 2 слой – 0.5	1 слой – 256 2 слой – 128	99.93 %	663 min 39 s
11	zerocenter	1 слой – Tanh 2 слой – Tanh 3 слой – Tanh	database_with_Gaussian_noise_v0.92_m0.92_1	1 слой – 0.2 2 слой – 0.2 3 слой – 0.2	1 слой – 250 2 слой – 200 3 слой – 128	99.28 %	671 min 44 s

От проведените експерименти може да се направи извод, че с прилагането на посочените видове нормализиране на входните данни, активационни функции и скрити единици на LSTM слоевете в границите, които са зададени, не указват влияние върху точността на валидиране.

Времето за обучение варира в близки граници за обучените модели с приложени еднакви dropout техники. Прилагането на dropout техника при разпространението на данните в мрежата, обучена с нарастване на вероятността в слоевете, от първия 0.2, на 0.5 във втория, се постига 100 % точност на

[www.eufunds.bg](http://www.eufunds.bg)

Проект BG05M2OP001-2.016-0003 „Модернизация на Национален военен университет "Васил Левски"- гр. Велико Търново и Софийски университет "Св. Климент Охридски" - гр. София, в професионално направление 5.3 Компютърна и комуникационна техника“, финансиран от Оперативна програма „Наука и образование за интелигентен растеж“, съфинансирана от Европейския съюз чрез Европейските структурни и инвестиционни фондове.



валидиране за мрежата и два пъти по-кратко време на обучение.

Сложността в изображенията, която произтича от различните нива на внесен адитивен шум на различните набори от данни, също не указва затруднение при обучението на моделите. Подходът за определяне на мрежовите архитектури изглежда правилен съгласно постигнатите резултати, което следва да се докаже от резултатите от работата на невронните мрежа в следващата глава.

Обучението на LSTM невронни мрежи за разпознаване на изображения с адитивен импулсен шум е аналогично на проведеното предходно обучение. Използвани са седем и деветслойни архитектури.

Обучението на мрежовите модели започва с обучаването на седем слойна LSTM мрежа без да бъде използвано нормализиране на данните. Резултатът показва, че мрежовия модел не може да се справи с обучението на алгоритъма, така както конволюционната мрежа успешно се обучи без да се прилага нормализиране на данните в първия слой.

За да бъдат потвърдени направените изводи, се обучи втора невронна мрежа с девет слоя и приложени хиперболични тангенсови активационни функции на LSTM слоевете.

*Таблица 4. LSTM мрежови модели обучени за разпознаване на изображения с адитивен импулсен шум.*

Брой слоеве	Нормализиране на данните	Активационна Функция на състоянието на слоеве LSTM	Набор от данни за обучение	Отпадащ слой (dropout техника с вероятност)	Брой скрити единици в LSTM слоевете	Точност на валидиран [%]	Време за обучение [min, s]
7	none	Softsign	database_with _Salt&Pepper _noise_d0.52_ 160	0.2	128	4.56 %	224 min 47 s
7	zscore	Softsign	database_with _Salt&Pepper _noise_d0.52_ 160	0.2	128	100 %	163 min 25 s
9	zerocenter	1 слой – Softsign 2 слой – Softsign	database_with _Salt&Pepper _noise_d0.52_ 160	1 слой – 0.2 2 слой – 0.2	1 слой – 256 2 слой – 128	99.95 %	190 min 6 s

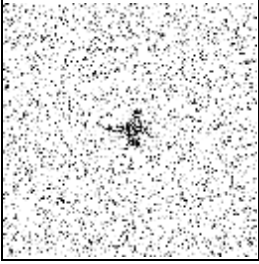
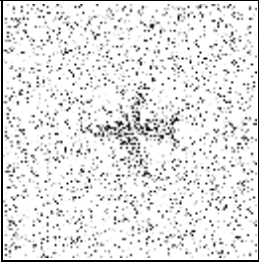
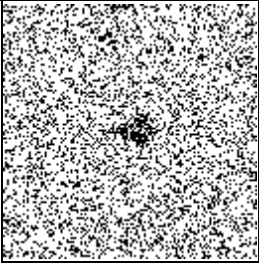


9	none	1 слой – Tanh 2 слой – Tanh	database_with _Salt&Pepper _noise_d0.52_160	1 слой – 0.2 2 слой – 0.2	1 слой – 256 2 слой – 128	4.66 %	210 min 43 s
7	zscore	Softsign	database_with _Salt&Pepper _noise_d0.72_120	0.2	128	99.43 %	196 min 21 s
7	zscore	Softsign	database_with _Salt&Pepper _noise_d0.72_120	0.5	128	99.51 %	192 min 31 s
9	zerocenter	1 слой – Softsign 2 слой – Softsign	database_with _Salt&Pepper _noise_d0.72_120	1 слой – 0.2 2 слой – 0.2	1 слой – 256 2 слой – 128	98.43 %	201 min 40 s
9	zerocenter	1 слой – Softsign 2 слой – Softsign	database_with _Salt&Pepper _noise_d0.72_120	1 слой – 0.5 2 слой – 0.5	1 слой – 256 2 слой – 128	98.47 %	200 min 50 s
9	zscore	1 слой – Softsign 2 слой – Softsign	database_with _Salt&Pepper _noise_d0.72_120	1 слой – 0.5 2 слой – 0.5	1 слой – 256 2 слой – 128	99.30 %	207 min 0 s
7	zscore	Softsign	database_with _Salt&Pepper _noise_d0.92_90	0.5	128	82.93 %	174 min 16 s
7	zscore	Tanh	database_with _Salt&Pepper _noise_d0.92_90	0.2	128	77.47 %	215 min 26 s
7	zscore	Tanh	database_with _Salt&Pepper _noise_d0.92_90	0.5	128	80.09 %	235 min 59 s
9	zerocenter	1 слой – Softsign 2 слой – Softsign	database_with _Salt&Pepper _noise_d0.92_90	1 слой – 0.2 2 слой – 0.2	1 слой – 256 2 слой – 128	75.17 %	183 min 17 s
9	zerocenter	1 слой – Softsign 2 слой – Softsign	database_with _Salt&Pepper _noise_d0.92_90	1 слой – 0.5 2 слой – 0.5	1 слой – 256 2 слой – 128	69.90 %	182 min 41 s

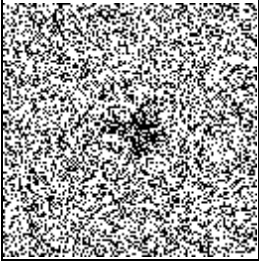
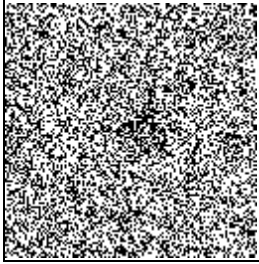
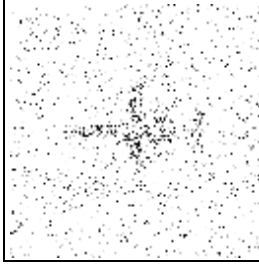
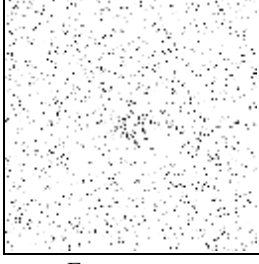




Таблица 5. Числени резултати от работата на част от обучените невронни мрежи.

Изображение с внесен шум и посочени характеристики	Числен резултат от разпознаването на следните невронни архитектури					
	CNN обучена за разпознаване на Гаусов шум	CNN обучена за разпознаване на Импулсен шум	LSTM невр. мрежа обучена за разпознаване на Гаусов шум	LSTM невр. мрежа обучена за разпознаване на Импулсен шум	Повторно обучена CNN обучена за разпознаване на двата шума	Повторно обучена LSTM невр. мрежа обучена за разпознаване на двата шума
 Гаусов шум: мат. очакване – 0.5; дисперсия – 0.5; модел M-346	Разпознат, с резултат 1.000	неприложимо	Разпознат, с резултат 0.9880	неприложимо	неприложимо	неприложимо
 Гаусов шум: мат. очакване – 1, дисперсия – 1; модел Falcon 8x	Разпознат, с резултат 0.9996	неприложимо	Разпознат, с резултат 0.9626	неприложимо	неприложимо	неприложимо
 Импулсен шум: плътност на шума – 0.5; модел Gripen E	неприложимо	Разпознат, с резултат 0.9998	неприложимо	Разпознат, с резултат 0.9904	неприложимо	неприложимо



 Импулсен шум: плътност на шума – 0.7; модел <b>F-35C</b>	неприложимо	Разпознат, с резултат 0.9997	неприложимо	Разпознат, с резултат 0.9535	неприложимо	неприложимо
 Импулсен шум: плътност на шума – 0.8; модел <b>Su-57</b>	неприложимо	Разпознат, с резултат 0.7647	неприложимо	Разпознат, с резултат 0.3078	неприложимо	неприложимо
 Гаусов шум: мат. очакване – 1, дисперсия – 1; Импулсен шум: плътност на шума – 0.8; модел <b>Fokker 100</b>	неприложимо	неприложимо	неприложимо	неприложимо	Разпознат, с резултат 0.9989	Разпознат, с резултат 0.9188
 Гаусов шум: мат. очакване – 1, дисперсия – 1; Импулсен шум: плътност на шума – 1; модел <b>Tornado</b>	неприложимо	неприложимо	неприложимо	неприложимо	Разпознат, с резултат 0.6806	Разпознат, с резултат 0.6203



ЕВРОПЕЙСКИ СЪЮЗ  
ЕВРОПЕЙСКИ  
СОЦИАЛЕН ФОНД



ОПЕРАТИВНА ПРОГРАМА  
НАУКА И ОБРАЗОВАНИЕ ЗА  
ИНТЕЛИГЕНТЕН РАСТЕЖ

Сравнение на числените резултати от работата на обучените невронни архитектури, имплементирани в разработеното софтуерно приложение, доказват високата производителност на моделираните алгоритми.

И двата типа невронни архитектури се справят успешно с решаване на поставената цел, в дисертационния труд, за правилно класифициране на радиолокационни изображения в среда с интензивни нива на шумови въздействия.

CNN имат по-добро представяне с по-високи резултати, с което запазват водеща позиция при задачата за разпознаване на обекти от изображения.

[www.eufunds.bg](http://www.eufunds.bg)

Проект BG05M2OP001-2.016-0003 „Модернизация на Национален военен университет "Васил Левски"- гр. Велико Търново и Софийски университет "Св. Климент Охридски" - гр. София, в професионално направление 5.3 Компютърна и комуникационна техника“, финансиран от Оперативна програма „Наука и образование за интелигентен растеж“, съфинансирана от Европейския съюз чрез Европейските структурни и инвестиционни фондове.